



IBM Developer
SKILLS NETWORK

Data-Driven Landing : analyse et prédiction des phases d'atterrissage de SpaceX Falcon 9

RADJI Nadjim Assissa
26/06/2026





SPACEX

Outline

P3	Executive Summary
P4	Introduction
P6	Methodology
P16	Results
P21	Conclusion
P33	Appendix



EXECUTIVE SUMMARY

- Summary of methodologies
 - Data Collection through API
 - Data Collection with Web Scraping
 - Data Wrangling
 - Exploratory Data Analysis with SQL
 - Exploratory Data Analysis with Data Visualization
 - Interactive Visual Analytics with Folium
 - Machine Learning Prediction
- Summary of all results
 - Exploratory Data Analysis result
 - Interactive analytics in screenshots
 - Predictive Analytics result



Introduction

1. Le Contexte : La révolution du spatial par le coût

SpaceX a bouleversé l'industrie aérospatiale en proposant des lancements de Falcon 9 à un coût ultra-compétitif de 62 millions de dollars, là où la concurrence historique dépasse souvent les 165 millions de dollars par lancement. L'origine d'une telle différence économique repose sur une innovation majeure : la capacité de SpaceX à récupérer et réutiliser le premier étage (le *booster*) de ses fusées.

2. La Problématique : Anticiper pour rivaliser

Prédire le succès de l'atterrissage est crucial pour évaluer le coût réel d'un lancement et permettre à des entreprises concurrentes de s'aligner. L'enjeu est de comprendre quels facteurs (météo, orbite, charge utile) et quelles conditions opérationnelles garantissent la réussite du retour sur Terre.

3. L'Objectif : Un pipeline de Machine Learning


Ce projet vise à concevoir un pipeline complet de Data Science et de Machine Learning pour analyser les données historiques des lancements et prédire avec précision la réussite de l'atterrissage du premier étage de Falcon 9.

Section 1

Methodology

Méthodologie de *préparation* des données

Étapes rigoureuses pour préparer les données pour l'analyse et la modélisation.



Collecte de données via l' *API* SpaceX

Extraction et normalisation des données
techniques de lancement.



Requête de données

Requête via API
SpaceX



Décodage / Conversion

.json() et
normalisation



Demande spécifique

Via des fonctions
personnalisées



Structuration

Création d'un
dictionnaire



Création d'un DataFrame

Conversion en
dataframe



Filtration

Lancements Falcon
9 uniquement



Traitement

Moyenne pour
Payload Mass



Exportation

Exporter vers
fichier CSV



Collecte par *Web*

Scraping Wikipédia

Extraction de données historiques à partir de tableaux HTML.



Demande des données de lancement Falcon 9 sur Wikipédia



Création d'un objet BeautifulSoup à partir de la réponse HTML



Extraction des noms de colonnes depuis l'en-tête du tableau HTML



Collecte des données par analyse des tableaux HTML



Création d'un dictionnaire à partir des données



Création d'un dataframe à partir du dictionnaire



Exportation des données vers un fichier CSV



Data Wrangling

Préparation des Données pour la Classification des Orbites




- **Phase d'exploration** : Analyser le dataset et définir les variables cibles pour l'entraînement du modèle.




- **Agrégation par site** : Comptabiliser le nombre de lancements par site, ainsi que la fréquence et le type d'orbite associé à chacun.



- **Génération de la cible + export** : Créer une colonne Résultat d'atterrissage à partir des données brutes, puis exporter le dataset final au format CSV.



EDA with Data Visualization



01 EDA with Data Visualization

Understanding the Dataset

POINTS CLÉS



Sites de lancement

Les lancements sont concentrés sur quelques sites, en particulier **CCAFS SLC 40**.



Capacité de charge utile

Les masses transportées augmentent globalement avec le numéro de vol.



Évolution des missions

Les missions récentes tendent à transporter des charges plus lourdes.




Performance

Les performances varient selon les sites et les caractéristiques des missions.


● Classe 0 : Échec ● Classe 1 : Succès



Launch Site by Flight Number




Payload Mass over Flight Number



02 EDA with Data Visualization


Key Findings

 Success Rate by Orbit Type



➤ Les orbites **GEO**, **HEO**, **ES-L1** et **SSO** affichent les taux de réussite les plus élevés.

 Success Rate Trend Over the Years



➤ Le taux de réussite s'améliore fortement au fil des années, atteignant **près de 90 %** pour les missions récentes.

CONCLUSIONS



Amélioration continue
des performances
au fil des années.



Des performances variables
selon le type d'orbite.



Des charges utiles de plus en plus lourdes
pour les missions récentes.



Activités concentrées
sur quelques sites,
notamment CCAFS SLC 40.

EDA with SQL



Explorer et comprendre la base de données à l'aide de **requêtes SQL** afin d'identifier les caractéristiques des missions SpaceX avant la phase de visualisation.

1 Exploration de la base



- Identification des sites de lancement
- Vérification de la structure des données
- Consultation des premiers enregistrements

2 Analyse des missions



- Calcul de la masse totale transportée
- Masse moyenne par version de booster
- Identification des boosters les plus performants

3 Analyse des atterrissages



- Première réussite sur plateforme terrestre
- Succès sur drone ship
- Classement des types d'atterrissage

4 Statistiques des missions



- Comptage des missions réussies
- Comptage des échecs
- Analyse des fréquences

5 Analyse temporelle



- Missions de l'année 2015
- Analyse par mois
- Comparaison des résultats dans le temps



Principaux enseignements



Identification des sites de lancement



Analyse des performances des boosters



Étude des résultats des missions



Extraction des indicateurs utiles à l'analyse exploratoire

Interactive Visual Analytics with Folium



Objectif

Visualiser les sites de lancement SpaceX sur une carte interactive afin d'analyser leur environnement et l'influence des infrastructures voisines sur les opérations de lancement.

1



Localisation des sites




- Géolocalisation des sites de lancement
- Visualisation de leur répartition sur le territoire américain

2



Analyse des proximités




- Calcul des distances vers les routes, bâtiments et côtes
- Identification des infrastructures à proximité

3



Carte interactive finale



- Intégration des résultats des lancements
- Distinction entre succès et échecs
- Exploration interactive des sites



Principaux enseignements



Les sites SpaceX sont concentrés sur quatre bases de lancement.



Les cartes interactives facilitent l'analyse de l'environnement de chaque site.



Les distances aux infrastructures constituent des variables utiles pour la prédiction des atterrissages.

Dashboard Analytics with Plotly Dash




Objectif

Développer un tableau de bord interactif permettant d'explorer les performances des lancements SpaceX selon le site de lancement et la masse de la charge utile.

1 Sélection du site de lancement


Total Success Launches By Site



- Sélection dynamique d'un site de lancement
- Comparaison des taux de réussite entre les différents sites

2 Analyse des performances


Total Success Launches for site CCAFS LC-40



- Visualisation des succès et des échecs
- Évaluation des performances pour un site donné

3 Corrélation charge utile / succès

Correlation between Payload and Success for all Sites



- Filtrage interactif par masse utile
- Étude de la relation entre la charge utile et le succès des missions



Principaux enseignements



Le tableau de bord permet une exploration interactive des données.



Les performances varient selon le site de lancement.



La masse de la charge utile influence le taux de réussite selon le contexte des missions.

Predictive Analysis

Utilisation des techniques de Machine Learning pour prédire le succès de l'atterrissage du premier étage de Falcon 9.




? Problématique

Peut-on prédire si le premier étage de Falcon 9 atterrira avec succès (land) ou non (did not land) à partir des caractéristiques de la mission ?

Données utilisées

- Données historiques des lancements SpaceX (missions Falcon 9)
- Variables explicatives : caractéristiques de la mission, charge utile, orbitales, etc.
- Variable cible : succès d'atterrissage (1 = **land**, 0 = **did not land**)

Approche adoptée



Objectifs

- ✓ Comparer plusieurs algorithmes pour identifier le plus performant
- ✓ Évaluer la capacité des modèles à généraliser sur de nouvelles missions
- ✓ Fournir un outil d'aide à la décision pour anticiper les succès d'atterrissage



Enjeux

Améliorer la compréhension des facteurs clés de succès et soutenir la prise de décision pour optimiser les futures missions SpaceX.


Predictive Analysis with Machine Learning



Objectif

Construire un modèle capable de prédire le succès d'un atterrissage de Falcon 9 à partir des caractéristiques des missions.

Pipeline de Machine Learning



Modèles évalués



Logistic Regression



Support Vector Machine



Decision Tree



K-Nearest Neighbours



Les hyperparamètres de chaque modèle ont été optimisés automatiquement grâce à **GridSearchCV** (validation croisée à 10 plis).


2. Model Evaluation

Performance des modèles

Modèle	Accuracy (Test)
Logistic Regression	83.3 %
Support Vector Machine	83.3 %
Decision Tree	83.3 %
K-Nearest Neighbours	83.3 %

✓ Les quatre algorithmes obtiennent la même accuracy de **83.3 %** sur le jeu de test.

Matrice de confusion (exemple)



Résultats

- ✓ 12 atterrissages correctement prédits
- ✓ 3 faux positifs
- ✓ Aucun faux négatif
- ✓ Accuracy ≈ **83 %**



Conclusion

Les quatre algorithmes obtiennent des performances similaires sur ce jeu de données. Le modèle présente une bonne capacité de généralisation mais reste limité par la taille relativement réduite du jeu de test.

RESULTS



Objectif atteint

Développement d'un pipeline complet de Data Science permettant d'analyser les missions Falcon 9 et de prédire le succès de l'atterrissage du premier étage.



Analyse des données

- Collecte des données via l'API SpaceX et le Web Scraping.
- Nettoyage, transformation et enrichissement du jeu de données.
- Identification des principaux facteurs influençant le succès des missions.



Visualisation et exploration

- Analyse exploratoire des données (EDA).
- Extraction d'indicateurs clés à l'aide de SQL.
- Cartographie interactive avec Folium.
- Tableau de bord interactif développé avec Plotly Dash.



Modélisation prédictive

- Évaluation de 4 algorithmes de Machine Learning.
- Optimisation automatique des hyperparamètres avec GridSearchCV.
- **Accuracy obtenue : 83,3 %** sur le jeu de test.



Principaux enseignements



Le **type d'orbite** est l'un des facteurs les plus influents sur le succès d'un atterrissage.



Les **missions Falcon 9 récentes** affichent une amélioration continue de leur taux de réussite.



Les **sites de lancement** présentent des performances distinctes selon les caractéristiques des missions.



Les **variables techniques** permettent de prédire efficacement le succès de l'atterrissage du premier étage.



Résultat global : Le projet démontre qu'un pipeline complet de Data Science — de la collecte des données à la modélisation prédictive — permet d'expliquer les performances des missions Falcon 9 et de prédire avec une précision satisfaisante le succès de l'atterrissage des boosters.



CONCLUSION



Objectif du projet

Développer un pipeline de Data Science complet pour analyser les missions Falcon 9 et prédire le succès de l'atterrissage du premier étage.



Objectifs atteints

- ✓ Collecte de données via l'API SpaceX et Web Scraping
- ✓ Nettoyage, transformation et préparation des données
- ✓ Analyse exploratoire approfondie (EDA)
- ✓ Requêtes SQL pour extraire des insights clés
- ✓ Cartographie interactive avec Folium
- ✓ Dashboard interactif avec Plotly Dash
- ✓ Construction et évaluation de modèles de Machine Learning performants



Meilleure performance obtenue : **83,3 %** d'accuracy sur le jeu de test.



Limites du projet

- Dataset relativement limité en taille.
- Absence de données météorologiques et de certains paramètres opérationnels.
- Déséquilibre des classes (missions réussies / échouées).
- Modèle encore perfectible sur la généralisation.



Perspectives

- Intégrer des données météorologiques et des variables opérationnelles supplémentaires.
- Tester d'autres algorithmes avancés (Random Forest, XGBoost, LightGBM).
- Collecter plus de données pour améliorer la généralisation du modèle.
- Déployer le modèle via une application Web (Streamlit, Flask) pour des prédictions en temps réel.



Message final

Les analyses réalisées montrent que les caractéristiques des missions Falcon 9, telles que le type d'orbite, le site de lancement, la masse de la charge utile et la version du booster, permettent de prédire efficacement le succès de l'atterrissage. Ce projet démontre la valeur d'un pipeline Data Science complet pour transformer des données brutes en décisions éclairées.



APPENDIX



Cette section regroupe des informations complémentaires et techniques détaillées.
Ces annexes sont disponibles pour approfondir certains aspects du projet.

Trois annexes pour aller plus loin

A

Appendix A Dataset & Variables

- Architecture du dataset
- Variables utilisées
- Variable cible
- Types de variables
- Statistiques clés (nombre d'observations, valeurs manquantes, etc.)

**B**


Appendix B SQL & Préparation des données

- Requêtes SQL principales
- Pipeline de préparation des données
- Traitement des valeurs manquantes
- Encodage des variables
- Hyperparamètres et grid search (GridSearchCV)

**C**

Appendix C Évaluation détaillée des modèles

- Courbes ROC et AUC
- Matrice de confusion
- Rapport de classification (precision, recall, F1-score)
- Importance des variables
- Comparaison détaillée des modèles



Objectif des annexes : fournir des détails techniques et des résultats approfondis pour répondre aux questions et valider la robustesse de l'approche adoptée.



APPENDIX A | Dataset Overview



Cette annexe présente les caractéristiques du jeu de données SpaceX Falcon 9 utilisé dans ce projet ainsi que les variables prises en compte pour l'analyse et la modélisation.



1. Dataset Summary



Observations

90

lancements



Variables brutes

18

variables



Variables après
encodage
(One-Hot Encoding)

80

variables



Variable cible

Class

(1 = Land,
0 = Did not land)



Période couverte

2010 - 2020



2. Data Sources



SpaceX
REST API



Wikipedia
(Web Scraping)



3. Main Features

- ✓ Flight Number
- ✓ Payload Mass (kg)
- ✓ Orbit
- ✓ Launch Site
- ✓ Booster Version
- ✓ Booster Flights
- ✓ Grid Fins
- ✓ Reused Booster
- ✓ Landing Pad

...



4. Data Preparation



Gestion des valeurs manquantes



Encodage One-Hot
des variables catégorielles



Création de variables dérivées
(Feature Engineering)



Dataset prêt pour l'apprentissage
machine et la modélisation



Note : Le dataset final combine des informations opérationnelles, orbitales et techniques du booster pour prédire le succès d'atterrissage du Falcon 9.



APPENDIX B | Data Pipeline & SQL Queries



Cette annexe présente les requêtes SQL utilisées pour la collecte des données ainsi que le pipeline de préparation avant le Machine Learning.



1. Requêtes SQL utilisées

a) Récupérer les informations des lancements

```
SELECT *  
FROM SPACEXDATASET.LAUNCHES  
ORDER BY FLIGHT_NUMBER;
```



b) Récupérer les détails des boosters

```
SELECT *  
FROM SPACEXDATASET.BOOSTERS  
ORDER BY BOOSTER_ID;
```



2. Pipeline de préparation des données



- ✓ **Nettoyage** : gestion des valeurs manquantes et suppression des doublons
- ✓ **Fusion** : combinaison des données API (launches, boosters, payloads, cores) et Web Scraping
- ✓ **Transformation** : encodage One-Hot des variables catégorielles
- ✓ **Résultat** : dataset final de 90 observations et 80 variables prêt pour le ML



3. Tables principales utilisées



LAUNCHES
Informations générales sur chaque lancement



BOOSTERS
Détails techniques des boosters



PAYLOADS
Caractéristiques des charges utiles



CORES
Informations sur la récupération



LANDING_PADS
Détails des sites d'atterrissage



Objectif : Collecter, intégrer et transformer les données pour obtenir un dataset fiable et exploitable pour prédire le succès d'atterrissage du Falcon 9.




Cette annexe présente les modèles de Machine Learning évalués, la méthodologie d'évaluation, les métriques utilisées et les performances obtenues pour prédire le succès d'atterrissage du Falcon 9.

1. Modèles évalués

- Logistic Regression
- Support Vector Machine (SVM)
- Decision Tree
- K-Nearest Neighbors (KNN)

Évaluation réalisée sur le dataset final : 90 observations, 80 variables après encodage One-Hot.

2. Pipeline d'évaluation



Méthode robuste pour éviter le surapprentissage et garantir la généralisation.

3. Performances des modèles

Modèle	Accuracy (Test Set)
Logistic Regression	83.3 %
SVM	83.3 %
Decision Tree	83.3 %
KNN	83.3 %

Les quatre modèles atteignent **83.3 % d'accuracy** sur le jeu de test.

4. Métriques utilisées

Accuracy
Précision globale

Confusion Matrix
Analyse des prédictions (succès / échec)

Classification Report
Précision, rappel, F1-score par classe

Cross Validation (10-fold)
Validation robuste des performances



Takeaway : Tous les modèles obtiennent des performances similaires avec **83.3 % d'accuracy**. Le modèle retenu a été sélectionné sur la base de la simplicité, de l'interprétabilité et de la robustesse.

Thank you!

